

# Аппроксимация временного ряда цен на золото

Романовский Илья, Серов Кирилл

Научный руководитель: Коваленко В. В., аспирант  
кафедры ОПУ

Научный руководитель: к.ф. - м.н. Заплетин М.П., доцент  
кафедры ОПУ

# Введение

## Цель работы

Разработка и апробация модели на основе ряда Фурье для анализа цен на золото

## Задачи исследования

- Предобработка и нормализация исторических данных
- Построение модели ряда Фурье с оптимизацией параметров
- Проверка точности аппроксимации и статистический анализ
- Визуализация результатов и сравнение с исходными данными

# Ряды Фурье

## Теорема Дирихле (ключевая теорема)

Для кусочно-непрерывных и монотонных функций ряд Фурье сходится:

$$f(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} \left( a_n \cos \frac{2\pi n t}{T} + b_n \sin \frac{2\pi n t}{T} \right)$$

где коэффициенты Фурье вычисляются по формулам:

$$a_n = \frac{2}{T} \int_0^T f(t) \cos \frac{2\pi n t}{T} dt$$

$$b_n = \frac{2}{T} \int_0^T f(t) \sin \frac{2\pi n t}{T} dt$$

## Представление ряда Фурье только через косинусы

$$f(t) = A_0 + \sum_{n=1}^N A_n \cos \left( \frac{2\pi n t}{T} + \phi_n \right)$$

- $$A_0 = \frac{a_0}{2}$$

$$A_n = \sqrt{a_n^2 + b_n^2} \quad (\text{амплитуда})$$

- $$\phi_n = -\arctan \left( \frac{b_n}{a_n} \right) \quad (\text{фаза})$$

### Преимущества

- Меньше параметров
- Снижение переобучения

# Метод ADAM: описание алгоритма

## Инициализация параметров

- $\theta_0 = \{A_0^{(0)}, A_1^{(0)}, \dots, A_N^{(0)}, \phi_1^{(0)}, \dots, \phi_N^{(0)}\}$
- $m_0 = \mathbb{E}[g_0] = 0,$
- $v_0 = \mathbb{E}[g_0^2] = 0,$
- $\beta_1 = 0.9, \beta_2 = 0.999$
- Learning rate:  $\alpha = 0.001$
- $\epsilon = 10^{-8}$
- $\mathcal{L}(\theta)$  - целевая функция, дифференцируемая по параметрам  $\theta$

# Метод ADAM: описание алгоритма

## Итеративное обновление

На каждой итерации  $t$ :

- 1 Вычисление градиента:

$$g_t = \nabla_{\theta} \mathcal{L}(\theta_{t-1}) \quad (1)$$

- 2 Обновление смещённой оценки первого момента (среднего градиентов):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2)$$

- 3 Обновление смещённой оценки второго момента (дисперсии градиентов):

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (3)$$

# Метод ADAM: описание алгоритма

## Итеративное обновление

❹ Коррекция смещения:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (4)$$

❺ Обновление параметров:

$$\theta_t = \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (5)$$

# Метод ADAM: описание алгоритма

## Контроль сходимости

- 1 Алгоритм прекращает работу, когда изменение параметров становится меньше заданного порога  $\epsilon_{\text{params}}$ :

$$\|\theta_t - \theta_{t-1}\|_2 < \epsilon_{\text{params}}$$

- 2 Дополнительный критерий основан на изменении значения функции потерь:

$$|\mathcal{L}_t - \mathcal{L}_{t-1}| < \epsilon_{\text{loss}}$$



# Метод ADAM: описание алгоритма

## Контроль сходимости

- 3 Для обеспечения устойчивости в алгоритме применяется регуляризация параметров:
  - Ограничение амплитуд:  $A_n \in [-10, 10]$
  - Ограничение фаз:  $\phi_n \in [-\pi, \pi]$
- 4 В качестве страховочного механизма установлено максимальное число итераций  $T_{\max} = 5000$ , что гарантирует завершение алгоритма даже при медленной сходимости.

# Метод градиентного спуска: описание алгоритма

## Инициализация параметров

- Начальный вектор оптимизируемых параметров:  
$$\theta_0 = \{A_0^{(0)}, A_1^{(0)}, \dots, A_N^{(0)}, \varphi_1^{(0)}, \dots, \varphi_N^{(0)}\}$$
- Скорость обучения (learning rate):  $\alpha = 0.001$
- Максимальное число итераций:  $T_{\max} = 5000$
- Порог остановки:  $\epsilon$  — минимальное изменение функции потерь или параметров для прекращения итераций

# Метод градиентного спуска: описание алгоритма

## Итеративное обновление

На каждой итерации  $t$ :

- 1 Вычисление градиента:

$$g_t = \nabla_{\theta} \mathcal{L}(\theta_{t-1})$$

- 2 Обновление параметров:

$$\theta_t = \theta_{t-1} - \alpha \cdot g_t$$

$$A_n^{(t)} = A_n^{(t-1)} - \alpha \cdot \frac{\partial \mathcal{L}}{\partial A_n}, \quad \varphi_n^{(t)} = \varphi_n^{(t-1)} - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \varphi_n}$$

# Метод градиентного спуска: описание алгоритма

## Итеративное обновление

- ➊ Проверка критериев остановки: Алгоритм прекращает работу, если выполнено хотя бы одно из условий:
  - Изменение параметров становится меньше заданного порога:

$$\|\theta_t - \theta_{t-1}\|_2 < \epsilon_{\text{params}}$$

- Изменение функции потерь становится меньше порога:

$$|\mathcal{L}(\theta_t) - \mathcal{L}(\theta_{t-1})| < \epsilon_{\text{loss}}$$

- Достигнуто максимальное число итераций  $T_{\text{max}}$

# Метод градиентного спуска: описание алгоритма

## Регуляризация параметров

- Амплитуды:  $A_n \in [-15, 15]$
- Фазы:  $\varphi_n \in [-\pi, \pi]$

## Преимущества метода

- Простота реализации
- Низкие вычислительные затраты на каждой итерации
- Быстрая сходимость при применении к простым функциям потерь

## Метод винзоризации

Для данных  $X = \{x_1, \dots, x_n\}$  и параметра  $\alpha \in [0, 0.5]$ :

$$x_i^* = \begin{cases} Q_\alpha, & \text{если } x_i < Q_\alpha \\ x_i, & \text{если } Q_\alpha \leq x_i \leq Q_{1-\alpha} \\ Q_{1-\alpha}, & \text{если } x_i > Q_{1-\alpha} \end{cases}$$

Где:

- $Q_\alpha$  — нижний  $\alpha$ -процентиль
- $Q_{1-\alpha}$  — верхний  $(1 - \alpha)$ -процентиль

## Применение

В работе использовано  $\alpha = 0.1$  (10% границы)

## Метод медианной замены

- ❶ Вычисляем границы выбросов:

$$\begin{cases} Q_{15} = \inf \{x | F_n(x) \geq 0.15\} \\ Q_{85} = \inf \{x | F_n(x) \geq 0.85\} \end{cases}$$

- ❷ Находим медиану выборки:

$$m = \text{med}(\ell_i) = F_n^{-1}(0.5)$$

- ❸ Заменяем аномальные значения:

$$\ell_i^* = \begin{cases} m, & \ell_i \notin [Q_{15}, Q_{85}] \\ \ell_i, & \text{иначе} \end{cases}$$

# Статистический анализ остатков аппроксимации

## Показатель Херста

Измеряет степень долгосрочной памяти временного ряда:

- $H \approx 0.5$  - белый шум (случайные колебания)
- $H > 0.5$  - персистентность (сохранение тенденций)
- $H < 0.5$  - антиперсистентность (частая смена направлений)

оценивается из следующего соотношения:

$$\frac{R(n)}{S(n)} \sim C \cdot n^H$$



## Показатель Херста: алгоритм оценки

- ❶ Разбиваем ряд на блоки размеров  $n_1, n_2, \dots, n_k$
- ❷ Для каждого блока вычисляем:
  - Кумулятивную сумму  $W_k = \sum_{i=1}^k X_i$
  - Размах  $R = \max W_k - \min W_k$
  - Нормированный размах  $R/S$ , где  $S$  - стандартное отклонение
- ❸ Усредняем по всем блокам:

$$\langle R/S \rangle_n = \frac{1}{m} \sum_{j=1}^m (R/S)_j$$

- ❹ Строим регрессию:

$$\log(R/S)_n = \log C + H \cdot \log n + \epsilon$$

## Показатель Херста: алгоритм оценки

- 5 Оцениваем показатель Херста (МНК)

$$\hat{H} = \frac{\sum_{i=1}^k (\log n_i - \overline{\log n})(\log \langle R/S \rangle_{n_i} - \overline{\log \langle R/S \rangle})}{\sum_{i=1}^k (\log n_i - \overline{\log n})^2}$$

где  $\overline{\log n}$ ,  $\overline{\log \langle R/S \rangle}$  – средние значения.

### Коррекция для малых выборок

Для рядов с  $N < 1000$  (в нашем случае  $N = 558$ ) применяем поправку Аньюса-Ллойда:

$$\hat{H}_{\text{корр}} = \hat{H} - \frac{\log \mathbb{E}[(R/S)_n]}{\log n}$$

# Коэффициент детерминации $R^2$

## Определение

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

- $SS_{\text{res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  (необъяснённая вариация)
- $SS_{\text{tot}} = \sum_{i=1}^n (y_i - \bar{y})^2$  (общая вариация)

## Интерпретация

- $R^2 = 1$ : идеальная аппроксимация
- $R^2 \approx 0$ : модель не лучше среднего
- Близость к 1: лучше объяснение данных

# Критерий Шапиро-Уилка

## Основные положения

- Нулевая гипотеза  $H_0$ : ошибки  $\sim \mathcal{N}(\mu, \sigma^2)$
- Альтернатива  $H_1$ : распределение не нормальное
- Особенно эффективен для  $n < 50$ , но применим для любых  $n$

## Статистика теста

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)}\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- $x_{(i)}$  - порядковые статистики
- $a_i$  - табличные коэффициенты

## Критерий Шапиро-Уилка

Если  $\mathbf{m} = (m_1, m_2, \dots, m_n)^T$  — вектор математических ожиданий порядковых статистик стандартного нормального распределения, а  $\mathbf{V}$  — их ковариационная матрица, то:

$$a = \frac{\mathbf{m}^T \mathbf{V}^{-1}}{(\mathbf{m}^T \mathbf{V}^{-1} \mathbf{V}^{-1} \mathbf{m})^{1/2}}$$

### Правила принятия решений

- $W \approx 1$  - нет оснований отвергать  $H_0$
- $W \ll 1$  - отклоняем  $H_0$  (распределение не нормальное)
- $p\text{-value} < 0.05$  - статистически значимые отклонения

# Критерий Колмогорова-Смирнова

## Основные положения

- Нулевая гипотеза  $H_0$ : ошибки  $\sim \mathcal{N}(\mu, \sigma^2)$
- Альтернатива  $H_1$ : распределение отлично от нормального
- Непараметрический критерий (не зависит от параметров распределения)

## Статистика критерия

$$D_n = \sup_x |F_n(x) - F(x)|$$

- $F_n(x)$  - эмпирическая функция распределения
- $F(x)$  - теоретическая нормальная  $\mathcal{N}(\bar{x}, s_x^2)$

# Критерий Колмогорова-Смирнова

## Интерпретация результатов

- $D_n \rightarrow 0$  - нет оснований отвергать  $H_0$
- $D_n > D_{crit}$  - отклоняем  $H_0$
- $p\text{-value} < 0.05$  - значимые отклонения от нормальности

## Особенности критерия

- Чувствителен к различиям в центре и хвостах распределения
- Требуется большого объема выборки для хорошей мощности

# Итоги исследования

## Что сделано

- Разработана модель на основе ряда Фурье с фазовым сдвигом
- Реализована оптимизация параметров (градиентный спуск и Adam)
- Рассмотрены методы борьбы с выбросами
- Проведена комплексная статистическая проверка модели
- Выполнена программная реализация на Python